

NEURA-CORE ENGINE v2.0-ULTRA

Documento de Diseño Técnico de Alto Detalle (TDD / GDD)

Proyecto: Neura-Core Afectivo	Autor: Alejandro Espinoza (InKing Studio)
Versión: 2.0.0-ULTRA	Fecha: Agosto 2026
Estado: Producción	Dominio: B2B AI Engines / Gaming / Simulation

1. Arquitectura Topológica y Pipeline Event-Driven

Neura-Core v2.0-ULTRA opera como un **Servidor Afectivo Centralizado** totalmente desacoplado del renderizado en cliente. La aplicación de escritorio Tauri contiene la UI React embebida y actúa como superficie principal; Unity, UE5, IVR y conexiones WebSocket/gRPC son integraciones externas opcionales, mientras Neura-Core gestiona la memoria, resolución afectiva y emisión de datos estructurados.

SLAs de Producción (P99):

- Affect Engine + Memory Query: < 80ms
- First Token SSE Response: < 350ms
- Sesiones concurrentes por nodo: 10,000

2. Especificación Detallada de Memoria Jerárquica (Modelo TencentDB)

A diferencia de arquitecturas RAG convencionales (base de datos vectorial plana que produce mezcla de contextos y alucinaciones temporales), Neura-Core implementa 4 niveles de memoria continua.

2.1. Desglose Operativo por Capas de Memoria

Nivel	Almacenamiento	Formato de Datos	Algoritmo de Ingesta	Costo Tokens
L0: Raw Log	Redis In-Memory Buffer (Cluster)	JSON / Circular Array (Timestamp, Speaker, Text, Pitch)	Sliding Window 10 msgs. TTL 24h.	~1,000-2,500 tokens
L1: Atomic Facts	Qdrant Vector DB / Milvus + Metadata	Vector + JSON Payload (Sujeto-Predicado-Objeto)	LLM Worker asíncrono cada N turnos; extrae tripletas.	~200-500 tokens (Top-K=5)
L2: Scenario Nodes	Neo4j Graph DB + Markdown Files	Grafo Relacional + Markdown AST / Mermaid	Clustering semántico: 3+ hechos L1 comparten contexto → crea nodo L2.	~300-800 tokens (Nodo activo)
L3: Core Persona	Flat .md / PostgreSQL	Documento JSON (Prompt Base, Reglas Éticas)	Actualización asíncrona vía cronjobs nocturnos desde L2.	~500-1,200 tokens (Constante)

2.2. Memoria Corta Simbólica (Mermaid Execution Canvas)

Cuando el agente invoca herramientas externas (APIs, pasarelas de pago, bases de datos), Neura-Core intercepta la respuesta JSON y la comprime en abstracción simbólica Mermaid:

Ejemplo comprimido (85% reducción de tokens):
graph TD; A[Inicio Reembolso]-->B{Gold?}; B-->|Sí| C[Stripe Refund ID_8921]; C-->E[HTTP 200 OK]; B-->|No| D[Escalar a Soporte];

- **Drill-Down:** Si nodo C falla (HTTP 500), el agente emite **DRILL_DOWN(node_id='C')** recuperando solo el log crudo Redis de esa llamada.

3. Especificación Matemática del Motor Afectivo (Matriz VAD)

Definición de Ejes:

- Valence (V) [-1.0, +1.0]: Calidad del afecto (-1.0 sufrimiento → +1.0 satisfacción).
- Arousal (A) [-1.0, +1.0]: Activación neurofisiológica (-1.0 calma → +1.0 excitación/ira).
- Dominance (D) [-1.0, +1.0]: Control percibido (-1.0 sumisión → +1.0 autoridad).

3.2. Decay Function (Tick Conversacional):

$$E_t = E_{(t-1)} + \alpha * \Delta E_{stimulus} - \Gamma * (E_{(t-1)} - E_{baseline}) + \eta(t)$$

$\alpha \in [0.1, 0.4]$ = coeficiente de reactividad | Γ = tasa de decaimiento inercial | $\eta(t) \sim N(0, Q)$ = ruido micro-afectivo estocástico

3.3. Cuadrantes Emocionales y Moduladores Vocal/UI

Centroide	VAD Target	Pitch	Rate	Vol	UI Color
Calma Profesional	(0.00,-0.20,+0.20)	1.00x	1.00x	0 dB	#64748B Slate
Empatía / Calidez	(+0.65,+0.10,+0.20)	1.04x	0.95x	-1 dB	#F59E0B Amber
Frustración / Ira	(-0.85,+0.80,+0.60)	0.92x	1.25x	+4 dB	#EF4444 Crimson
Ansiedad / Miedo	(-0.60,+0.70,-0.70)	1.15x	1.30x	-2 dB	#A855F7 Purple
Tristeza / Apología	(-0.50,-0.60,-0.50)	0.88x	0.80x	-3 dB	#3B82F6 Blue
Entusiasmo / Éxito	(+0.85,+0.85,+0.50)	1.10x	1.12x	+2 dB	#10B981 Emerald

4. Payloads de Producción (Input / Output JSON)

4.1. Payload de Entrada (Client Request Event):

```
{
  "client_id": "unity-game-instance-9021",
  "session_id": "sess-8849-ax2-2026",
  "agent_id": "neura-npc-merchant-v1",
  "timestamp": 1785675530,
  "input_payload": {
    "type": "AUDIO_TRANSCRIPTION",
    "raw_text": "¡Es un robo! Tu poción costaba 50 monedas la semana pasada...",
    "sentiment_hint_from_stt": {
      "audio_pitch_avg": 240.5,
      "audio_volume_db": 12.4,
      "perceived_user_arousal": 0.85
    }
  },
  "client_context": {
    "location_id": "town_square_shop",
    "in_game_time": "14:30",
    "user_reputation_score": -12
  }
}
```

4.2. Payload de Salida (Cognitive & Affective Output):

```
{
  "event_id": "evt-99102-neura",
  "agent_id": "neura-npc-merchant-v1",
  "execution_latency_ms": 184,
  "affect_state": {
    "primary_emotion": "DEFENSIVE_ANGER",
    "vad_vector": {
      "valence": -0.72,
      "arousal": 0.78,
      "dominance": 0.65
    },
    "delta_applied": {
      "valence_change": -0.35,
      "arousal_change": 0.40,
      "dominance_change": 0.15
    },
    "emotional_intensity": 0.82,
    "ui_visual_cue": {
      "hex_color": "#DC2626",
      "pulse_frequency_hz": 2.5
    }
  },
  "memory_trace": {
    "active_l2_scenario": "MERCHANT_PRICE_HAGGLING",
    "retrieved_l1_facts": [
      "user_previously_stole_an_apple",
      "potion_ingredients_increased_due_to_dragon_event"
    ],
    "memory_drilldown_used": false
  },
  "cognitive_output": {
    "internal_thought": "El cliente me insultó y tiene mala reputación. No cederé.",
    "response_text": "¡Cuida tu lengua en mi tienda! Las raíces de mandrágora subieron...",
    "speech_synthesis_config": {
      "engine": "ELEVEN_LABS_STREAMING",
      "voice_id": "Merchant_Garrick_v2",
      "pitch_modifier": 0.92,
      "rate_modifier": 1.18,
      "volume_gain_db": 3.5
    },
    "behavioral_triggers": {
      "animation_tag": "GESTURE_POINT_FINGER_ANGRY",
      "facial_blendshape_preset": "EXPRESSION_ANGRY_INTENSE"
    }
  }
}
```

```
"client_events": [{"event_name": "PLAY_SFX_TABLE_SLAM", "delay_ms": 100}, {"event_name": "MODIFY_NPC_DISCOUNT_PERCENT", "value": 0}]]}
```

5. Casos de Uso Empresariales (Verticales B2B)

Vertical	Escenario	Dinámica Clave Neura-Core
Enterprise HR / Customer Support	Entrenamiento de ejecutivos en manejo de crisis (vuelos cancelados, disputas).	Cliente VAD (-0.80,+0.85,+0.40). El motor evalúa en tiempo real la reducción de arousal y emite EQ Score final.
EdTech / Salud Clínica	Simulaciones de entrevistas clínicas para estudiantes de psicología.	L2 garantiza consistencia de síntomas durante entrevistas 45+ min sin alterar historial.
Gaming & Metaverse RPG	NPCs autónomos de alta fidelidad en mundos virtuales interactivos.	Cliente gráfico solo procesa animaciones (FSM). Neura-Core gestiona toda la cognición en la nube.

6. Roadmap de Despliegue de Infraestructura

Fase	Período	Componentes	Meta Técnica
Fase 1: Memory Subsystem	Meses 1-2	Redis Cluster + Qdrant Vector DB + Mermaid Compression Engine	Retrieval P99 < 45ms
Fase 2: Affect Core Engine	Meses 3-4	Matriz VAD Rust / ElevenLabs SSML Streaming / EKF Pipeline	1,000 req/sec por nodo
Fase 3: B2B SDKs & APIs	Meses 5-6	Unity C# Plugin, Unreal Engine 5 C++ Subsystem, Dashboard Analítico B2B	SDK v1.0 stable + SLA 99.9%